ARHITECTURA SISTEMELOR DE CALCUL - CURS 0x00

INFORMAȚII ADMINISTRATIVE

Cristian Rusu

CUPRINS

- cadre didactice
- organizare
- evaluare
- structura cursului
- · obiectivele cursului
- referințe bibliografice generale

CADRE DIDACTICE

- Cristian Rusu
 - curs şi seminar
 - contact: <u>cristian.rusu@unibuc.ro</u>
 - pagină web curs: https://cs.unibuc.ro/~crusu/asc/index.html

- Bogdan Macovei şi Ruxandra Bălucea
 - laborator
 - contact
 - bogdan.macovei.fmi@gmail.com
 - ruxandra.balucea@unibuc.ro

organizare:

- 2h curs / săptămână
- 2h seminar / 2 săptămâni
- 2h laborator / 2 săptămâni

evaluare:

- 70% examen (online, cu materiale, ultimul curs)
 - doar examenul final se repetă la restanță
- 30% laborator
 - 2 x 10% două teme (predare în lunile noiembrie și decembrie)
 - 10% evaluare finală la laborator (ultimul laborator)
- 10% extra
 - proiecte (în grup) discutate la curs, vor fi 3 sau 4

condiții de promovare:

- peste 50% la laborator, pentru fiercare din cele două criterii separat
 - atenție, dacă acest punctaj nu este îndeplinit laboratorul trebuie refăcut în următorul an universitar
- peste 50% la examenul final

- din cauza pandemiei COVID-19
- cursul va fi integral online, prezența nu este obligatorie
- laboratorul va fi integral online, prezenţa obligatorie
- seminarul va fi online
 - începem online
 - în cazul în care valul COVID-19 se termină, putem să ne vedem
 - prezenţa nu va fi obligatorie, vine doar cine doreşte
 - cel puţin un seminar va fi online şi înregistrat (pentru cei care nu vor/pot să ajungă fizic)
- binenţeles, ne supunem regulilor statului şi universităţii

- pentru curs/seminar/laborator
 - vă rog să aveţi funcţionale microfon/camera video (vrem să comunicăm cu voi, deci avem nevoie să vă vedem şi să vă auzim)
 - în timpul activităților vă rog să țineți microfon/camera dezactivate
 - vă vom ruga noi să activați microfon/camera pentru a comunica
 - fiți pregatiti cu hartie/pix pentru a nota idei fundamentale și pentru exerciții (materialele le aveți și electronic, dar unele probleme vor fi lucrate împreună atât la curs cât și la seminar)
 - aveţi nevoie de un laptop/computer pentru laborator
- pentru examen: intră orice e prezentat la curs/seminar/laborator (cu excepția unor slide-uri/concepte care sunt explicit menționate)

pentru seminar

- vor fi exerciții cu noțiunile pe care le întâlnim la curs
- mereu încerc să vă ofer mai multe probleme decât putem face în cele două ore o dată la două săptămâni
- ce rămâne, este temă
- ce nu puteți să faceți puteți întreba la cursul/seminarul următor
- seminarul ține pasul cu ce facem la curs

pentru laborator

- multă programare
- Assembly x86
- veţi vedea şi Linux/Git/limbajul C
- sunt două părți: câte 3 laboratoare fiecare
- la curs acoperim teoria de la laborator de abia din săptămâna 6
- după aproximativ o lună veţi putea evalua dificultatea materiei

- nu mai sunteți la liceu
- acum nu mai repetăm același tip de probleme/exerciții

cursul

- accentul este pus pe concepte
- accentul este pus pe a înțelege ce se întâmplă
- ideea este cel mai imporant lucru

seminar şi laborator

- exerciții cu conceptele de la curs
- cimentăm ce am văzut la curs
- aici e multă muncă individuală
- vă încurajăm să lucrați împreună și să colaborați pentru a înțelege, dar nu să copiați

NU COPIAȚI/PLAGIAȚI

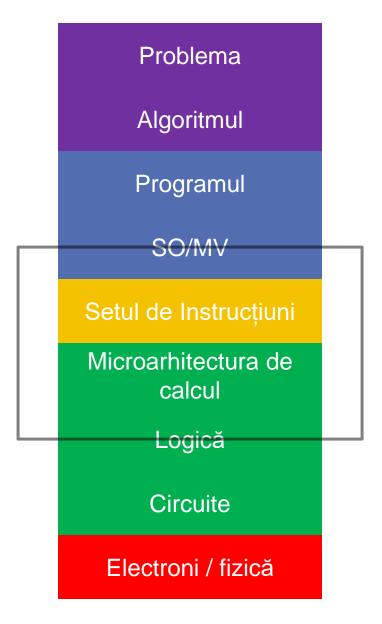
- pedeapsa pentru copiat nu este doar că veți pica materia
- veţi fi raportaţi la comisia de etică şi riscaţi exmatricularea
- fără copy/paste la seminar/laborator/teme/test/examen
- fără copiat de la colegi (riscați toți)

STRUCTURA CURSULUI

- circuite digitale
 - teoria informației și abstractizarea digitală
 - funcții și circuite logice
- arhitecturi de calcul

 materia acoperită la laborator începe de aici
 - seturi de instrucţiuni
 - limbajul assembly
 - compilatoare
 - pipelining
 - ierarhia memoriei
- organizarea calculatoarelor
 - unitatea de procesare centrală
 - performanţa calculatoarelor
 - dispozitive periferice şi întreruperi
 - calcul paralel
- potenţiale subiecte moderne la curs: RISC-V, WebAssembly, TockOS, hardware pentru machine learning (GPU, TPU, etc.), etc.
- laborator: progamare în limbajul Assembly x86

POZIȚIONAREA CURSULUI



OBIECTIVELE CURSULUI


- să înțelegeți principile arhitecturii sistemelor de calcul
 - ce urmărim
 - ce limitări există
 - punerea în balanță a unor criterii de performanță contradictorii
- să înțelegeți ce există ca tehnologie acum
 - ce limitări există astăzi
 - ce execută un computer pe care îl programați voi
 - cum puteți optimiza execuția programelor
- să înțelegeți cum să folosiți ce ați învățat în viitor
 - design de hardware nou
- pentru a ne asigura că lucrurile merg bine, veți avea posibilitatea să oferiți feedback (anonim binențeles) la jumătatea cursului
- pe parcurs, dacă sunt probleme sau neclarități vă rog sa mi le comunicați (e-mail, la clasă, fie direct sau anonim sau printr-un reprezentant, etc.)

OBIECTIVELE CURSULUI

- să înțelegeți principile arhitecturii sistemelor de calcul
 - ce urmărim
 - ce limitări există
 - punerea în balanță a unor criterii de performanță contradictorii
- să înțelegeți ce există ca tehnologie acum
 - ce limitări există astăzi
 - ce execută un computer pe care îl programați voi
 - cum puteți optimiza execuția programelor
- să înțelegeți cum să folosiți ce ați învățat în viitor
 - design de hardware nou
- pentru a ne asigura că lucrurile merg bine, veţi avea posibilitatea să oferiţi feedback (anonim binenţeles) la jumătatea cursului
- pe parcurs, dacă sunt probleme sau neclarități vă rog sa mi le comunicați (e-mail, la clasă, fie direct sau anonim sau printr-un reprezentant, etc.)

"The purpose of computing is insight, not numbers." (Richard Hamming)

PROGRESUL TEHNOLOGIC FĂCUT



- înainte de al doilea razboi mondial, 1939, USA
- putere de calcul: 50 operații / secundă

- ENIAC
- 1947 1955, USA
- 1000 operații / secundă

• FUGAKU, 2020, Japonia

core-uri: 7.630.848

• memorie: 5.087.232 GB

537.212 trilioane operații / secundă



- hardware pentru machine learning (învățare automată)
- DeepMind şi OpenAl vorbesc despre două lucruri:
 - algoritmi noi pentru modelare și antrenare
 - "compute" (infrastructura hardware pe care rulează algoritmii)



- AlphaZero: software bazat de ML
 - Stockfish (software clasic bazat pe metode de căutare – în principal alpha/beta pruning)
 - 3500 ELO
 - AlphaZero vs Stockfish:
 - +155 -6 =839
 - Magnus Carlsen (campionul mondial actual)
 - < 2900 ELO</p>
 - AlphaZero (alb)
 vs Stockfish (negru)



https://science.sciencemag.org/content/362/6419/1140.full , https://en.wikipedia.org/wiki/AlphaZero , https://www.youtube.com/watch?v=IFXJWPhDsS

- hardware pentru machine learning (învățare automată)
- DeepMind şi OpenAl vorbesc despre două lucruri:
 - algoritmi noi pentru modelare și antrenare
 - "compute" (infrastructura hardware pe care rulează algoritmii)



AlphaZero: software bazat de ML

- Stockfish (software clasic bazat pe metode de căutare – în principal alpha/beta pruning)
 - 3500 ELO
- DeepMind spune că a antrenat acest algoritm 4 ore (învățat din self-play)
 - da, 4 ore pe platforma lor de calcul
 - un calcul rapid, aproximativ, arată că pe laptop-ul meu aceeași procedură de antrenare ar dura 30 de ani
 - costul? aproximativ 20\$ milioane
- cum scădem costul?
 - algoritmi mai eficienti
 - hardware special, dedicat

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

- nmulțește două matrice
- care este complexitatea numerică?

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

# varianta B
for (int j = 0; j < n; ++j)
  for (int i = 0; i < n; ++i)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

- înmulțește două matrice
- care este complexitatea numerică?
 - $O(n^3)$
 - 2n³ operații
 - ce face varianta B?

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

# varianta B
for (int j = 0; j < n; ++j)
  for (int i = 0; i < n; ++i)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

- înmulțește două matrice
- care este complexitatea numerică?
 - $O(n^3)$
 - 2n³ operaţii
- ce face varianta B?
- cei doi algoritmi sunt echivalenţi, matematic

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

# varianta B
for (int j = 0; j < n; ++j)
  for (int i = 0; i < n; ++i)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

- înmulţeşte două matrice
- care este complexitatea numerică?
 - $O(n^3)$
 - 2n³ operații
- ce face varianta B?
- cei doi algoritmi sunt echivalenţi, matematic

care algoritm se execută mai rapid?

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

# varianta B
for (int j = 0; j < n; ++j)
  for (int i = 0; i < n; ++i)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

- înmulţeşte două matrice
- care este complexitatea numerică?
 - $O(n^3)$
 - 2n³ operații
- ce face varianta B?
- cei doi algoritmi sunt echivalenţi, matematic

pe sistemul meu de calcul varianta B este de 4 ori mai lentă decât varianta A cum este posibil așa ceva?

care este diferența dintre cele două variante?

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

# varianta B
for (int j = 0; j < n; ++j)
  for (int i = 0; i < n; ++i)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

- înmulțește două matrice
- care este complexitatea numerică?
 - $O(n^3)$
 - 2n³ operații
- ce face varianta B?
- cei doi algoritmi sunt echivalenţi, matematic

pe sistemul meu de calcul varianta B este de 4 ori mai lentă decât varianta A cum este posibil așa ceva?

care este diferența dintre cele două variante?

ordinea în care se execută instrucțiunile este foarte importantă

- ASC e importantă și pentru software-ul folosit de zi cu zi
- ce face următorul algoritm?

```
# varianta A
for (int i = 0; i < n; ++i)
  for (int j = 0; j < n; ++j)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];

# varianta B
for (int j = 0; j < n; ++j)
  for (int i = 0; i < n; ++i)
    for (int k = 0; k < n; ++k)
        C[i][j] += A[i][k] * B[k][j];</pre>
```

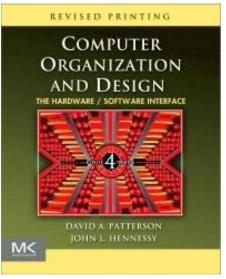
- înmulțește două matrice
- care este complexitatea numerică?
 - $O(n^3)$
 - 2n³ operaţii
- există un algoritm care calculează rezultatul *C* în *O*(*n*^{2.8074})
 - din păcate, pe arhitecturile de calcul moderne, acest algoritm este mai lent decât metoda clasică (o formă de varianta A)

concluzii:

- complexitatea numerică este foarte importantă, dar nu este totul
- ce calculăm matematic și ce putem executa sunt două lucruri diferite
- câteodată progresul în lumea reală este surprinzător și complet neevident

REFERINȚE BIBLIOGRAFICE GENERALE

D. Patterson and J. Hennessy, Computer Organisation and Design (PH book)



- Chris Terman, 6.004 Computation Structures, MIT, 2017
- MIT Computer Architecture Group: http://groups.csail.mit.edu/cag/
- aceste slide-uri se bazează şi pe alte cursuri de ASC la UB (R. Olimid şi D. Dragulici)

La sfârșitul fiecarui curs veți avea o listă de referințe specială pentru conținutul acelui curs

UN DEMO PENTRU FINAL

- ce putem face dacă înțelegem arhitectura sistemelor de calcul / assembly / sisteme de operare / tehnologii web?
- Doom 3 rulat in browser (demo WebAssembly):

http://wasm.continuation-labs.com/d3demo/